






**PUCP**



MAESTRÍA EN ECONOMÍA  
ECONOMETRÍA INTERMEDIA  
ECO743 – MÓDULO 2

# Sesión 1

## Perturbaciones No Esféricas - Heterocedasticidad

Docente: Juan Palomino



1

Supuestos MCO

2

Propiedades Estadísticas MCO

3

Perturbaciones No Esféricas

4

Propiedades en presencia de  
Perturbaciones No Esféricas

5

Mínimos Cuadrados Generalizados

6

Heterocedasticidad

7

Detección de Heterocedasticidad

8

Estimación bajo Heterocedasticidad

# 1. Supuestos MCO

---

## Supuesto 1: Linealidad

La relación entre la variable dependiente y las variables independientes es lineal. El modelo poblacional es:

$$y_i = \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_K x_{iK} + \varepsilon_i \quad i = 1, \dots, n$$

Donde  $\beta$ 's son parámetros desconocidos a ser estimados, y  $\varepsilon_i$  son términos de errores observados.

**Nota:** La propiedad de linealidad es una propiedad de los parámetros, no de las variables.

## Supuesto 2: Exogeneidad Estricta

El valor esperado de la perturbación aleatoria debe ser cero para cualquier observación:

$$E[\varepsilon_i|X] = 0 \quad i = 1, 2, \dots, n$$

Para cualquier valor de  $x_1, x_2, \dots, x_K$  en la población, el promedio no observable es igual a cero.

## Consecuencias de Exogeneidad Estricta:

### Definición: Ley de Esperanzas Iteradas

Si  $E|y| < \infty$ , es decir, la esperanza poblacional de  $y$  existe, entonces para cualquier vector  $x$  aleatorio:

$$E_x[E(y|x)] = E(y)$$

### 1. Media Incondicional

La media incondicional del término de error es cero:

$$E(\varepsilon_i) = 0$$

## Consecuencias de Exogeneidad Estricta:

### 2. Regresores son ortogonales al término de error

Si  $E(xy)$  de dos variables aleatorias  $x$  e  $y$  es cero, entonces decimos que  $x$  es ortogonal a  $y$ . Bajo exogeneidad estricta, los regresores son ortogonales al término de error para todas las observaciones, es decir, no comparten información.

$$E(x_{jk}\varepsilon_i) = 0 \quad i, j = 1, 2, \dots, n \quad k = 1, \dots, K$$

o

$$E(x \cdot \varepsilon_i) = \begin{pmatrix} E(x_{j1}\varepsilon_i) \\ E(x_{j2}\varepsilon_i) \\ \vdots \\ E(x_{jK}\varepsilon_i) \end{pmatrix} = \underbrace{0}_{K \times 1} \quad \forall i, j$$



## Consecuencias de Exogeneidad Estricta:

### 3. Condición de cero correlación

El regresos no está correlacionado con el término de error:

$$\text{Cov}(\varepsilon_i, x_{jk}) = 0$$

### 4. Media condicional de $y_i$

La media condicional de la variable dependiente es una función lineal de los regresores.

Bajo el supuesto de linealidad y exogeneidad estricta:

$$E(y_i|X) = x_i'\beta \quad i = 1, 2, \dots, n$$

## Supuesto 3: Rango Completo

Asume que ninguna de las variables en el modelo es una combinación lineal exacta de las otras.

*$X$  es una matriz  $n \times K$  con rango  $K$*

Significa que  $X$  tiene rango de columna completo.

**Nota:** El rango de una matriz es igual al número de columnas linealmente independientes de la matriz. También se le conoce como **condición de identificación**.

## Supuesto 4: Perturbaciones Esféricas

### ❖ Homocedasticidad

Asume que todas las unidades tienen el mismo error de varianza

$$E[\varepsilon_i^2 | X] = \sigma_0^2 > 0 \quad i = 1, 2, \dots, n$$

### ❖ No Correlación

Asume también que no hay correlación entre las observaciones

$$E[\varepsilon_i \varepsilon_j | X] = 0 \quad i, j = 1, 2, \dots, n \quad i \neq j$$

## Supuesto 5: Regresores no estocásticos

Las observaciones de  $x_i$  son fijos en muestras repetidas.

Asumir que los  $X$  son fijos quiere decir que, en repetidas muestras de  $X$ , los valores obtenidos  $x_1, x_2, \dots, x_K$  van a ser siempre los mismos; es decir, dejan de ser aleatorios.

Bajo este supuesto, ya no es necesario hablar de esperanzas condicionales:

$$E(\varepsilon_i) = 0$$

$$\text{Var}(\varepsilon_i) = \sigma^2$$

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$$

## Supuesto 6: Normalidad de los errores

$\varepsilon_i$  distribuye normal con media cero y varianza  $\sigma^2$  condicional a  $X$ :

$$\varepsilon_i|X \sim N(0, \sigma^2), \quad i = 1, 2, \dots, n$$

## 2. Propiedades Estadísticas de MCO

---

# Insesgadez del Estimador de MCO

## Estimador Insesgado

Un estimador  $\hat{\theta}$  para  $\theta_0$  es insesgado si  $E(\hat{\theta}) = \theta_0$

## Teorema 1: Insesgadez del Estimador MCO

Bajo el supuesto de Linealidad, Exogeneidad Estricta y Rango Completo:

$$E(\hat{\beta}|X) = \beta_0$$

Entonces,  $\hat{\beta}$  es un estimador insesgado de  $\beta_0$

# Insesgadez del Estimador de MCO

## Ejemplo:

Tenemos el siguiente modelo:

$$bmi_i = \alpha_0 + \beta_0 income_i + \varepsilon_i$$

Donde  $\beta_0$  es el efecto del ingreso sobre obesidad y es igual a 1.

El siguiente paso es conseguir una muestra de la población y obtener un estimado de  $\beta_0$ , llamado  $\hat{\beta}$ .

Imaginen lo siguiente:  $B = 50$  muestras de 1000 individuos y para cada muestra estimamos  $\beta$ .

$$\text{1era muestra} \rightarrow \hat{\beta}_1 = 0.9$$

$$\text{2da muestra} \rightarrow \hat{\beta}_1 = 0.94$$

$$\text{3era muestra} \rightarrow \hat{\beta}_1 = 0.7$$

$$\text{50ava muestra} \rightarrow \hat{\beta}_1 = 0.5$$

En promedio de las 50 muestras, conseguir:  $(\frac{1}{B}) \sum_{b=1}^B \hat{\beta}_b \approx 1$



# Insesgadez del Estimador de MCO

## Demostración

Tenemos:

$$\hat{\beta} = (X'X)^{-1}X'y$$

$$\hat{\beta} = (X'X)^{-1}X'(X\beta_0 + \varepsilon)$$

$$\hat{\beta} = (X'X)^{-1}X'X\beta_0 + (X'X)^{-1}X'\varepsilon$$

$$\hat{\beta} = \beta_0 + (X'X)^{-1}X'\varepsilon$$

$$\hat{\beta} - \beta_0 = A\varepsilon$$

Donde  $A = (X'X)^{-1}X'$ . Se le conoce como **sampling error**.

## Teorema 2: Varianza del estimador MCO

Bajo el supuesto de Linealidad, Exogeneidad Estricta, Rango Completo y Errores Esféricos:

$$\text{Var}(\hat{\beta}_{OLS}) = \sigma_0^2 (X'X)^{-1}$$

Entonces,  $\hat{\beta}$  es un estimador insesgado de  $\beta_0$

## Teorema 3: Gauss-Markov

Bajo todos los supuestos, el estimador MCO es eficiente en la clase de estimadores lineales insesgados. Es decir, para cualquier estimador insesgado  $\tilde{\beta}$  que es lineal en  $y$ ,

$$\text{Var}(\tilde{\beta}) \geq \text{Var}(\hat{\beta}_{OLS}|X)$$

Este teorema señala que el estimador MCO es eficiente en el sentido que su matriz de varianza-covarianza  $\text{Var}(\hat{\beta}_{OLS}|X)$  es el más pequeño entre todos los estimadores insesgados. Por esta razón, al estimador MCO se le conoce como Mejor Estimador Lineal Insesgado (MELI) [Best Linear Unbiased Estimator (BLUE)].

## Teorema 4: Covarianza entre $\hat{\beta}$ y $\hat{\varepsilon}$

Bajo todos los supuestos de Linealidad, Exogeneidad Estricta, Rango Completo, y Errores Esféricos:

$$\text{Cov}(\hat{\beta}, \hat{\varepsilon} | X) = 0$$

Donde  $\hat{\varepsilon} \equiv y - X\hat{\beta}$

# Covarianza entre $\hat{\beta}$ y $\hat{\varepsilon}$

## Demostración

$$\begin{aligned} \text{Cov}(\hat{\beta}, \hat{\varepsilon}|X) &= E\{[(\hat{\beta} - E(\hat{\beta}|X))][\hat{\varepsilon} - E(\hat{\varepsilon}|X)]'|X\} \\ &= E\{[(\hat{\beta} - \beta_0|X)][M\varepsilon - E(M\varepsilon|X)]'|X\} \\ &= E[A\varepsilon\varepsilon'M|X] \\ &= AE[\varepsilon\varepsilon'|X]M' \\ &= AE[\sigma_0^2 I_n]M \\ &= \sigma_0^2 (X'X)^{-1} X'M \\ &= \sigma_0^2 (X'X)^{-1} \underbrace{(MX)'}_0 \\ &= 0 \end{aligned}$$

## Teorema 5: Insesgadez de $\hat{\sigma}^2$

Bajo todos los supuestos de Linealidad, Exogeneidad Estricta, Rango Completo, y Errores Esféricos:

$$E(\hat{\sigma}^2|X) = \sigma_0^2$$

Siempre que  $n > K$ , de modo que  $\hat{\sigma}^2$  está bien definido.

## Demostración

Ya que  $\hat{\sigma}^2 = \frac{\hat{\varepsilon}'\hat{\varepsilon}}{(n-K)}$ , la prueba equivale a mostrar que  $E(\hat{\varepsilon}'\hat{\varepsilon}|X) = (n-K)\sigma_0^2$ . Sabemos que  $\hat{\varepsilon}'\hat{\varepsilon} = \varepsilon M \varepsilon$ , donde  $M$  es la matriz aniquiladora. La demostración consiste en probar dos propiedades: (1)  $E(\varepsilon M \varepsilon | X) = \sigma_0^2 \cdot \text{traza}(M)$ , y (2)  $\text{traza}(M) = n - K$ .

1. Probar que  $E(\varepsilon M \varepsilon | X) = \sigma_0^2 \cdot \text{traza}(M)$ : ya que  $\varepsilon' M \varepsilon = \sum_{i=1}^n \sum_{j=1}^n m_{ij} \varepsilon_i \varepsilon_j$ , tenemos:

$$E(\varepsilon M \varepsilon | X) = \sum_{i=1}^n \sum_{j=1}^n m_{ij} E(\varepsilon_i \varepsilon_j | X)$$

Ya que  $m_{ij}$ 's son funciones de  $X$

$$E(\varepsilon M \varepsilon | X) = \sum_{j=1}^n m_{ii} \sigma^2$$

Ya que  $E(\varepsilon_i \varepsilon_j | X) = 0$  para  $i \neq j$  por supuesto 4

$$E(\varepsilon M \varepsilon | X) = \sigma^2 \sum_{j=1}^n m_{ii} = \sigma^2 \cdot \text{traza}(M)$$

## Demostración

2. Probar que  $\text{traza}(M) = n - K$

$$\text{traza}(M) = \text{traza}(I_n - P)$$

Ya que  $P = X(X'X)^{-1}X'$

$$\text{traza}(M) = \text{traza}(I_n) - \text{traza}(P)$$

El operador de la traza es lineal

$$\text{traza}(M) = n - \text{traza}(P)$$

y

$$\text{traza}(P) = \text{traza}[X(X'X)^{-1}X']$$

Ya que  $P = X(X'X)^{-1}X'$

$$\text{traza}(P) = \text{traza}[(X'X)^{-1}X'X]$$

Ya que  $\text{traza}(AB) = \text{traza}(BA)$

$$\text{traza}(P) = \text{traza}[I_K]$$

$$\text{traza}(P) = K$$

Por lo tanto,  $\text{traza}(M) = n - K$



# 3. Perturbaciones Esféricas y No Esféricas

---

## 3.1 Perturbaciones Esféricas

## Supuesto: Perturbaciones Esféricas

### ❖ Homocedasticidad

Asume que todas las unidades tienen el mismo error de varianza

$$E[\varepsilon_i^2 | X] = \sigma_0^2 > 0 \quad i = 1, 2, \dots, n$$

### ❖ No Correlación

Asume también que no hay correlación entre las observaciones

$$E[\varepsilon_i \varepsilon_j | X] = 0 \quad i, j = 1, 2, \dots, n \quad i \neq j$$

Este supuesto señala que la varianza de todos los términos de errores es constante.

Para ver esto:

$$Var(\varepsilon_i|X) = E(\varepsilon_i^2|X) - [E(\varepsilon_i|X)]^2 \quad \text{(Por varianza condicional)}$$

$$Var(\varepsilon_i|X) = E(\varepsilon_i^2|X) \quad \text{(Por exogeneidad estricta)}$$

Similarmente, la covarianza de la distribución conjunta de  $(\varepsilon_i \varepsilon_j)$  condicional a  $X$  es cero.

$$Cov(\varepsilon_i \varepsilon_j | X) = 0 \quad (i, j = 1, 2, \dots, n \quad i \neq j)$$

$$E(\varepsilon_i \varepsilon_j | X) - E(\varepsilon_i | X)E(\varepsilon_j | X) = 0$$

$$E(\varepsilon_i \varepsilon_j | X) = 0$$

En notación matricial:

$$E(\varepsilon\varepsilon'|X) = \begin{pmatrix} E(\varepsilon_1\varepsilon_1|X) & E(\varepsilon_1\varepsilon_2|X) & \cdots & E(\varepsilon_1\varepsilon_n|X) \\ E(\varepsilon_2\varepsilon_1|X) & E(\varepsilon_2\varepsilon_2|X) & \cdots & E(\varepsilon_2\varepsilon_n|X) \\ \vdots & \vdots & \ddots & \vdots \\ E(\varepsilon_n\varepsilon_1|X) & E(\varepsilon_n\varepsilon_2|X) & \cdots & E(\varepsilon_n\varepsilon_n|X) \end{pmatrix}$$


$$E(\varepsilon\varepsilon'|X) = \begin{pmatrix} \sigma_0^2 & 0 & \cdots & 0 \\ 0 & \sigma_0^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_0^2 \end{pmatrix} = \sigma_0^2 I_n$$

Los términos de errores que cumplen los supuestos de homocedasticidad y no autocorrelación son llamados “**perturbaciones o errores esféricas**”.


- ¿Qué consecuencias tiene el no cumplimiento de este supuesto?
- ¿Cómo afecta las propiedades estadísticas del estimador de MCO?

## Supuesto de Homocedasticidad

Varianza del error no observable  $\varepsilon$  condicionado sobre las variables explicativas es constante.



Homocedasticidad



Heterocedasticidad

# 3. Perturbaciones No Esféricas

---

## 3.2 Perturbaciones No Esféricas

# Perturbaciones No Esféricas - Definición

Recordemos que hemos asumido que:

$$Var(\varepsilon|X) = \sigma_0^2 I_n = \begin{pmatrix} \sigma_0^2 & 0 & \dots & 0 \\ 0 & \sigma_0^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_0^2 \end{pmatrix}$$

Eliminando el supuesto de homocedasticidad:

$$Var(\varepsilon|X) = E(\varepsilon\varepsilon'|X) = \sigma_0^2 \Omega(X)$$



# Perturbaciones No Esféricas - Definición

La matriz  $\Omega(X)$  es no singular y conocida. Esta matriz puede contener elementos distintos en su diagonal principal y elementos diferentes de cero fuera de su diagonal:

$$\Omega(X) = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1n} \\ \sigma_{12} & \sigma_2^2 & \dots & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{12} & \sigma_{2n} & \dots & \sigma_n^2 \end{bmatrix}$$

Es decir, la varianza no es necesariamente constante y la covarianza entre diferentes perturbaciones podría ser diferente de cero.

## 4. Propiedades del Estimador $\hat{\beta}$ en presencia de Perturbaciones No Esféricas

---

# Consecuencias de relajar el supuesto: Insesgadez

Evaluar insesgadez:

$$E(\hat{\beta}_{MCO}|X) = ?$$

Demostración?

# Consecuencias de relajar el supuesto: Insesgadez

## Demostración

Tenemos:

$$\hat{\beta} = (X'X)^{-1}X'y$$

$$\hat{\beta} = (X'X)^{-1}X'(X\beta_0 + \varepsilon)$$

$$\hat{\beta} = (X'X)^{-1}X'X\beta_0 + (X'X)^{-1}X'\varepsilon$$

$$\hat{\beta} = \beta_0 + (X'X)^{-1}X'\varepsilon$$

Luego:

$$E(\hat{\beta}_{MCO}|X) = \beta + (X'X)^{-1}X'E(\varepsilon|X)$$

$$E(\hat{\beta}_{MCO}|X) = \beta$$

Sigue siendo **insesgado**.

# Consecuencias de relajar el supuesto: Varianza

Recordemos que la matriz de varianza-covarianza homocedástica es:

$$Var(\hat{\beta}_{MCO}) = \sigma_0^2 (X'X)^{-1}$$

Demostración?

# Consecuencias de relajar el supuesto: Varianza

## Demostración: Varianza Homocedástica

Tenemos:

$$Var(\hat{\beta}|X) = E(\hat{\beta} - E[\hat{\beta}|X])^2 \quad \text{(Por varianza condicional)}$$

$$Var(\hat{\beta}|X) = E(\hat{\beta} - \beta_0|X)^2 \quad \text{(Por insesgadez)}$$

$$Var(\hat{\beta}|X) = E(A\varepsilon|X)^2 \quad \text{(Por sampling error)}$$

$$Var(\hat{\beta}|X) = E(A\varepsilon\varepsilon'A'|X) \quad \text{(Forma cuadrática)}$$

$$Var(\hat{\beta}|X) = AE(\varepsilon\varepsilon'|X)A' \quad \text{(A es una función de X)}$$

$$Var(\hat{\beta}|X) = A(\sigma_0^2 I_n)A' \quad \text{(Por homocedasticidad)}$$

$$Var(\hat{\beta}|X) = \sigma_0^2 AA'$$

$$Var(\hat{\beta}|X) = \sigma_0^2 (X'X)^{-1}$$

# Consecuencias de relajar el supuesto: Varianza

Evaluar matriz de varianza-covarianza no homocedástica:

$$Var(\hat{\beta}_{MCO}) = ?$$

Demostración?

# Consecuencias de relajar el supuesto: Varianza

## Demostración: Varianza No Homocedástica

Tenemos:

$$Var(\hat{\beta}_{MCO}|X) = E[(\hat{\beta} - E(\hat{\beta})) (\hat{\beta} - E(\hat{\beta}))' | X]$$

$$Var(\hat{\beta}_{MCO}|X) = E(\hat{\beta} - E(\hat{\beta})|X)^2$$

$$Var(\hat{\beta}_{MCO}|X) = E(\hat{\beta} - \beta_0|X)^2$$

$$Var(\hat{\beta}|X) = E(A\varepsilon|X)^2 \quad \text{(Por sampling error)}$$

$$Var(\hat{\beta}_{MCO}|X) = E(A\varepsilon\varepsilon'A'|X) \quad \text{(Forma cuadrática)}$$

$$Var(\hat{\beta}_{MCO}|X) = AE(\varepsilon\varepsilon'|X)A' \quad \text{(A es una función de X)}$$

$$Var(\hat{\beta}_{MCO}|X) = (X'X)^{-1}X'E(\varepsilon\varepsilon')X(X'X)^{-1}$$

$$Var(\hat{\beta}_{MCO}|X) = (X'X)^{-1}X'\Omega X(X'X)^{-1}$$

Esta difiere de la matriz de varianza-covarianza homocedástica



# Consecuencias de relajar el supuesto

El estimador de  $\sigma^2$ ,  $\hat{\sigma}^2 = \frac{\hat{\varepsilon}'\hat{\varepsilon}}{n-K}$ , ya no es insesgado. Tarea: **Demostrarlo**.

El Teorema de Gauss Markov no se mantiene, por lo tanto el estimador MCO no son MELI.

¿Por qué?

El estadístico  $t$  y  $F$  no son válidas. Los estadísticos utilizados en los intervalos de confianza y en los contrastes de hipótesis ya no siguen las distribución señaladas, de modo que carecen de validez.

# 5. Mínimos Cuadrados Generalizados

---

## 5.1 MCG

# Mínimos Cuadrados Generalizados

- Dado los fallos que ocurren en las propiedades de los estimadores MCO, surge la conveniencia de buscar estimadores alternativos que verifiquen mejores propiedades que los de MCO.
- Este es el caso de los estimadores de Mínimos Cuadrados Generalizados (MCG)
- Para construirlos basta observar una propiedad del nuevo modelo, que depende de la descomposición de la matriz de varianza-covarianza de las perturbaciones.

# Modelo Transformado

- Dado que  $\Omega$  por construcción es una matriz simétrica y definida positiva, podemos encontrar una matriz  $C$  no singular (cuadrada) y de orden  $n$  tal que:

$$\Omega^{-1} = C' C$$

- La inversa de  $\Omega$  también debe ser una matriz positiva definida y simétrica, y  $C$  es una matriz  $n \times n$  no singular. Es posible reescribir:

$$\Omega = (C' C)^{-1} = C^{-1} (C')^{-1}$$

$$C \Omega C' = C C^{-1} (C')^{-1} C' = I$$

# Modelo Transformado

- Crear un nuevo modelo de regresión transformando  $(y, X, \varepsilon)$  por  $C$  como:

$$\tilde{y} \equiv Cy \qquad \tilde{X} \equiv CX \qquad \tilde{\varepsilon} \equiv C\varepsilon$$

- Por supuesto de linealidad para  $(y, X, \varepsilon)$  implica que  $(\tilde{y}, \tilde{X}, \tilde{\varepsilon})$  también satisface linealidad:

$$\tilde{y} = \tilde{X}\beta_0 + \tilde{\varepsilon}$$

- Supongamos que la matriz  $C$ , que aún no sabemos como es, cumple su objetivo, teniendo entonces que  $E(\tilde{\varepsilon}|\tilde{X}) = 0$  y  $Var(\tilde{\varepsilon}|\tilde{X}) = \sigma_0^2 I_n$ .

# Modelo Transformado

Este modelo transformado cumple supuesto de exogeneidad estricta:

$$E(\tilde{\varepsilon}|\tilde{X}) = ?$$

## Demostración: Exogeneidad Estricta

Tenemos:

$$\begin{aligned} E(\tilde{\varepsilon}|\tilde{X}) &= E(\tilde{\varepsilon}|X) \\ &= E(C\varepsilon|X) \\ &= CE(\varepsilon|X) \\ &= 0 \end{aligned}$$

Supuesto de homocedasticidad se cumple para el modelo transformado:

$$E(\tilde{\varepsilon}\tilde{\varepsilon}'|\tilde{X}) = ?$$

## Demostración: Homocedasticidad

Tenemos:

$$\begin{aligned} E(\tilde{\varepsilon}\tilde{\varepsilon}'|\tilde{X}) &= E(\tilde{\varepsilon}\tilde{\varepsilon}'|X) \\ &= CE(\varepsilon\varepsilon'|X)C' \\ &= C\sigma_0^2\Omega C' \\ &= \sigma_0^2 C\Omega C' \\ &= \sigma_0^2 I_n \end{aligned}$$

Finalmente,  $\tilde{\varepsilon}|\tilde{X}$  es normal porque la distribución de  $\tilde{\varepsilon}|\tilde{X}$  es la misma que  $\tilde{\varepsilon}|X$  y  $\tilde{\varepsilon}$  es una transformación lineal de  $\varepsilon$

- Estimador de mínimo cuadrados generalizados

$$\hat{\beta}_{MCG} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y}$$

$$\hat{\beta}_{MCG} = [(CX)'(CX)]^{-1}(CX)'Cy$$

$$\hat{\beta}_{MCG} = (X'C'CX)^{-1}(X'C'Cy)$$

$$\hat{\beta}_{MCG} = (X'\Omega^{-1}X)^{-1}(X'\Omega^{-1}y)$$



## Demostración: Insesgadez de $\hat{\beta}_{MCG}$

Tomando el valor esperado de  $\hat{\beta}_{MCG}$ :

$$E(\hat{\beta}_{MCG}|X) = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}E(y|X)$$

$$E(\hat{\beta}_{MCG}|X) = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}E(X\beta_0 + \varepsilon|X)$$

$$E(\hat{\beta}_{MCG}|X) = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}X\beta_0$$

$$E(\hat{\beta}_{MCG}|X) = \beta_0$$

El estimador sigue siendo insesgado.

Su varianza condicional es:

$$Var(\hat{\beta}_{MCG}|X) = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}Var(y|X)\Omega^{-1}X'(X'\Omega^{-1}X)^{-1}$$

$$Var(\hat{\beta}_{MCG}|X) = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}(\sigma^2\Omega)\Omega^{-1}X'(X'\Omega^{-1}X)^{-1}$$

$$Var(\hat{\beta}_{MCG}|X) = \sigma^2(X'\Omega^{-1}X)^{-1}$$

El estimador  $\hat{\beta}_{MCG}$  es eficiente (mínima varianza).

## ❖ Teorema de Aitken

El estimador  $\hat{\beta}_{MCG}$  es lineal, insesgado y su varianza es incluso menor que la varianza de MCO.

$$Var(\hat{\beta}_{MCG}|X) < Var(\hat{\beta}_{MCO}|X)$$

$$\sigma^2(X'\Omega^{-1}X)^{-1} < \sigma_0^2(X'X)^{-1}$$

Para el modelo de perturbaciones no esféricas, el estimador MCG es el de menor varianza dentro de la clase de estimadores lineales e insesgados.

- El estimador insesgado de  $\sigma^2$  es:

$$\hat{\sigma}^2 = \frac{(y - X\hat{\beta}_{MCG})'\Omega^{-1}(y - X\hat{\beta}_{MCG})'}{n - k}$$

- Se verifica que el estadístico:

$$\frac{\hat{\beta}_{MCG} - \beta}{\sqrt{\widehat{Var}(\hat{\beta}_{MCG})}} \sim t(n - k)$$

- Dicho estadístico se puede utilizar para obtener el intervalo de confianza para  $\beta$  a un nivel de confianza  $1 - \alpha$ :

$$\hat{\beta}_{MCG} \pm t_{n-k; 1-\frac{\alpha}{2}} \sqrt{\widehat{Var}(\hat{\beta}_{MCG})}$$

- Así como resolver contrastes de hipótesis sobre  $\beta$
- Si se quiere contrastar:

$$H_0: R\beta = r$$

$$H_1: R\beta \neq r$$

- El estadístico de contraste es:

$$F = \frac{(R\hat{\beta}_{MCG} - r)' [R(X'\Omega^{-1}X)R']^{-1} (R\hat{\beta}_{MCG} - r) / \#r}{q\hat{\sigma}_{MCG}^2} \sim F(q, n - k)$$

De forma que se rechaza  $H_0$  si  $F_{exp} > F_{q, n-k; 1-\alpha}$ .

# 5. Mínimos Cuadrados Generalizados

---

## 5.2 Mínimos Cuadrados Generalizados Factibles

## ¿Y si $\Omega$ no es conocida?

- En la práctica, la matriz  $\Omega$  raramente es conocida, por lo que el estimador MCG no se puede calcular.
- La alternativa es sustituir esta matriz por un estimador suyo  $\hat{\Omega}$ , obteniendo así el estimador de mínimos cuadrados generalizados factibles (MCGF)

$$\hat{\beta}_{MCGF} = (X' \hat{\Omega}^{-1} X)^{-1} (X' \hat{\Omega}^{-1} y)$$

- Como consecuencia, las propiedades que satisface el vector de estimadores MCG ya no se mantienen. De esta forma, el estimador MCGF, en general, no es insesgado ni óptimo.

# 6. Heterocedasticidad

---



# Naturaleza de la Heterocedasticidad

## ❖ Hipótesis de homocedasticidad

$$\text{var}(\varepsilon_i) = \sigma^2, \forall i = 1, \dots, n$$

## ❖ Hipótesis de heterocedasticidad

$$\text{var}(\varepsilon_i) = \sigma_i^2, \forall i = 1, \dots, n$$

Caso especial de perturbaciones esféricas que se presenta cuando la varianza de los términos de perturbación no es la misma para cada individuo o unidad de análisis:

$$\text{Var}(\varepsilon|X) = \begin{pmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n^2 \end{pmatrix}$$

Los términos de perturbación siguen siendo independientes.

# Naturaleza de la Heterocedasticidad






Figura 1. Heterocedasticidad

# Causas de la Heterocedasticidad

1. Con base en los modelos de aprendizaje de los errores, a medida que las personas aprenden, disminuyen sus errores de comportamiento con el tiempo.
2. La presencia de datos atípicos provoca una mayor variabilidad del error.



**Ejemplo.** Prueba de mecanografía



**Ejemplo.** Relación entre precios de acciones y precios al consumidor

# Causas de la Heterocedasticidad

3. A medida que mejoran las técnicas de recolección de datos, es probable que  $\sigma_i^2$  se reduzca. **Ejemplo:** bancos con equipos complejos de procesamiento de información cometan menos errores en los informes mensuales.
4. Otra fuente de la heterocedasticidad es la asimetría en la distribución de uno o más regresores incluidos en el modelo. **Ejemplo:** variables económicas como riqueza, ingreso y escolaridad. La riqueza le corresponde a uno o cuantos individuos pertenecientes a los estratos superiores.
5. Surge debido a i) la incorrecta transformación de los datos (transformaciones de razón o de primeras diferencias) y ii) una forma funcional incorrecta (modelos lineales frente a modelos log-lineales)
6. Omisión de variables importantes en el modelo.

**Nota:** La heterocedasticidad es un problema típico de modelos que utilizan datos de corte transversal.

# Consecuencias de la Heterocedasticidad

- Estimación sesgada de la varianza,  $\sigma^2$
- Los estimadores MCO son insesgados, pero menos eficientes que los MCG (es decir, no tienen varianza mínima).
- Los intervalos de confianza y los estadísticos utilizados para resolver contrastes de hipótesis ya no son fiables. Por tanto, existe la posibilidad de extraer conclusiones erróneas.

# 7. Detección de Heterocedasticidad

---

# Detección de heterocedasticidad

- No es fácil detectar la heterocedasticidad en una situación concreta, ya que  $\sigma_i^2$  solo se puede conocer si tenemos toda la población de  $Y$  correspondiente al valor  $X_i$ .
- En algunas ocasiones la propia naturaleza del problema sugiere si es probable que exista heterocedasticidad.
- Disponemos de varias herramientas de diagnóstico que nos pueden ayudar a detectar la heterocedasticidad.
- Se clasifican en:
  - Procedimientos informales o subjetivos
  - Procedimientos formales u objetivos

# 8. Detección de Heterocedasticidad

---

## 8.1 Procedimientos Informales



Son subjetivos y se basan en la representación gráfica de los residuos:

- Se calculan los residuos estimados del modelo por MCO.
- Se representan los  $\hat{\varepsilon}_i^2$  o los  $\hat{\varepsilon}_i$  frente a los  $\hat{Y}_i$ , o bien frente a la variable que se cree que provoca la heterocedasticidad.
- Si los puntos se disponen en el gráfico de forma aleatoria, no hay evidencia de que se incumpla la hipótesis de homocedasticidad.
- Si el gráfico muestra un patrón de comportamiento (lineal, cuadrático, exponencial, etc.) es probable que haya heterocedasticidad.

# Procedimientos Informales




Figura 2. Procedimiento Informal

# 8. Detección de Heterocedasticidad

---

## 8.2 Procedimientos Formales

# Procedimientos Formales

Son objetivos ya que se trata de contrastes de hipótesis.

- Existe diversos test de heterocedasticidad, cada uno de los cuáles parte de un determinado supuesto acerca del posible patrón de heterocedasticidad:
  - Test de Goldfeld-Quant
  - Test de Breusch-Pagan (1979)
  - Test de Glesjer
  - Test de White (1980)
- Cada uno de estos test plantea como hipótesis nula la ausencia de heterocedasticidad pero se diferencian entre sí en la forma de plantear la hipótesis alternativa.

# Test de Goldfeld-Quant

- Este test supone que la varianza de las perturbaciones (heterocedasticidad) está relacionada, normalmente, con una de las variables explicativas del modelo.
- Bajo el supuesto de que dicha dependencia sea, por ejemplo, positiva (los menores/mayores valores de la varianza se producen cuando los valores de la variable son menores/mayores).

# Test de Goldfeld-Quant

## ❖ Pasos:

1. Ordenar de menor a mayor los valores respecto a  $X_i$ , donde se supone que ésta es la variable explicativa causante de la heterocedasticidad.
2. Se omiten las  $c$  observaciones centrales.
3. Realizar dos estimaciones por MCO utilizando las  $\frac{N-c}{2}$  primeras observaciones y las  $\frac{N-c}{2}$  últimas observaciones.
4. Calcular la suma de los cuadrados de los residuos asociados a las dos estimaciones ( $SCR_1, SCR_2$ )
5. Bajo el supuesto de homocedasticidad se verifica que:

$$\frac{SCR_2}{SCR_1} \sim F_{\frac{N-c}{2}-k}$$

Con lo cual, fijado un nivel de significancia  $\alpha$ , rechazaremos la homocedasticidad si:

$$\frac{SCR_2}{SCR_1} > F_{\frac{N-c}{2}-k; 1-\alpha}$$

## ❖ Inconvenientes:

- ¿Cómo elegir  $c$ ?  $\rightarrow c \approx \frac{N}{3}$
- ¿Y si desconocemos cuál es la variable  $X_i$  causante de la heterocedasticidad o se sospecha de varias variables a la vez?

# Test de Breusch Pagan/Godfrey

- **Supuesto:** La heterocedasticidad está provocada por una o más variables, no necesariamente presentes en el modelo lineal inicial.
- Se supone que la varianza del término de error depende de un vector de  $p$  variables  $Z$ , del siguiente modo:

$$\sigma_i^2 = f(\alpha_0 + \alpha_1 Z_{1i} + \cdots + \alpha_p Z_{pi})$$

- Donde  $f$  es una forma funcional cualquiera,  $\alpha_j$ ,  $j = 0, \dots, p$ , parámetros y  $Z_1, \dots, Z_p$  las variables presumiblemente causantes de la heterocedasticidad.
- En consecuencia, contrastar la heterocedasticidad equivale a probar la hipótesis:

$$H_0: \alpha_1 = \alpha_2 = \cdots = \alpha_p = 0$$

$$H_0: \text{Algunos de ellos es no nulo}$$



# Test Breusch Pagan/Godfrey

## ❖ Pasos:

1. Estimar la ecuación principal  $y = X\beta + \varepsilon$  por MCO y calcular los residuos y los residuos al cuadrado.
2. Calcular el estimador de  $\sigma^2$ :  $\hat{\sigma}^2 = \frac{\hat{\varepsilon}'\hat{\varepsilon}}{n}$
3. Generar una nueva variable  $g_i = \frac{\hat{\varepsilon}_i^2}{\hat{\sigma}^2}$ ,  $i = 1, \dots, n$
4. Regresionar  $g_i$  contra  $Z_1, Z_2, \dots, Z_p$ :

$$g_i = \alpha_0 + \alpha_1 Z_{1i} + \dots + \alpha_p Z_{pi} + v_i$$

5. Estimar  $\alpha_0, \dots, \alpha_p$  por MCO y calcular la SCE de la regresión auxiliar.
6. Bajo la hipótesis nula de homocedasticidad y normalidad del término de error; se sabe que:

$$\frac{1}{2} SCE \sim \chi^2_{(p-1)}$$

7. Por tanto, se rechaza la hipótesis nula de homocedasticidad cuando:

$$Q_{exp} > \chi^2_{(p-1); 1-\alpha}$$

- **Supuesto:** La heterocedasticidad está provocada por una o más variables del modelo:

$$\sigma_i^2 = f(X_2, X_3, \dots, X_k)$$

Donde  $f(\cdot)$  es una función polinómica.

# Test de White

## ❖ Pasos:

1. Estimar por MCO el modelo  $y = X\beta + \varepsilon$  y obtener los residuos  $\hat{\varepsilon}_i$  y  $\hat{\varepsilon}_i^2$ .
2. Hacer la regresión de los residuos al cuadrado con respecto a todas las variables explicativas, sus cuadrados y todos sus productos cruzados. Por ejemplo, para un modelo con dos variables explicativas:

$$\hat{\varepsilon}_i^2 = \alpha_0 + \alpha_1 X_{1i} + \alpha_2 X_{2i} + \alpha_3 X_{1i}^2 + \alpha_4 X_{2i}^2 + \alpha_5 X_{1i}X_{2i} + v_i$$

3. La hipótesis nula de homocedasticidad es:  $H_0: \alpha_i = 0$
4. Bajo esta hipótesis, el estadístico:

$$n \times R_{aux}^2 \sim \chi_p^2$$

Donde  $p$  es el número de variables explicativas en dicha regresión.

5. Así, se rechaza la hipótesis de homocedasticidad si:

$$n \times R_{aux}^2 > \chi_{p,1-\alpha}^2$$

# 8. Estimación bajo Heterocedasticidad

---

## 8.1 Matriz $\Omega$ conocida

# 1. Mínimos Cuadrados Ponderados (MCP)

- En presencia de heterocedasticidad, MCO ya no es el mejor estimador lineal insesgado.
- Si se conoce la forma de la heterocedasticidad puede usarse la estimación por Mínimos Cuadrados Ponderados (MCP) para obtener estimadores más eficientes que los de MCO.
- Los estimadores MCP nos conducen a nuevos estadísticos  $t$  y  $F$  que tienen distribuciones  $t$  y  $F$ , respectivamente.
- La idea básica del procedimiento de Mínimos Cuadrados Ponderados se basa en transformar el modelo verdadero para que el término de error sea homocedástico.

# 1. Mínimos Cuadrados Ponderados (MCP)

Siendo el modelo a estimar:

$$y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + \varepsilon_i$$

No sabemos a ciencia cierta de qué depende la varianza del error  $\varepsilon_i$ , y, por lo tanto, no sabemos cómo construir la matriz  $\Omega(X)$ .

Empezamos haciendo una conjetura acerca de esta estructura de heterocedasticidad, asumiendo que:

$$Var(\varepsilon_i | x_1, \dots, x_n) = \sigma_i^2 = \sigma_0^2 \exp(x_i' \alpha)$$

Donde  $\exp(\cdot)$  asegura que  $Var(\varepsilon_i | x_1, \dots, x_n) > 0$ . Asumimos que  $\Omega$  es diagonal. Sea  $h_i(X)$  los elementos diagonal de  $\Omega(X)$ . Por lo tanto,

$$Var(\varepsilon_i | X) = \sigma_i^2 = \sigma_0^2 h_i(X)$$

Donde  $h_i(X)$  son conocidos y positivos. Asimismo,  $h_i(X)$  determina la heterocedasticidad.

# 1. Mínimos Cuadrados Ponderados (MCP)

- ¿Qué modelo estimamos? El modelo transformado es:

$$Cy = CX\beta_0 + C\varepsilon$$

Recordar que el estimador MCG es:

$$\hat{\beta}_{MCG} = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}y$$

Donde:

$$\Omega^{-1} = \begin{pmatrix} 1/h_i & 0 & \cdots & 0 \\ 0 & 1/h_i & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1/h_i \end{pmatrix} = C'C$$

- Entonces, en este caso particular,  $\Omega^{-1}$  es matriz diagonal cuyo elemento es  $1/h_i$ . Es decir:

$$C = \begin{pmatrix} \sqrt{h_1} & 0 & \cdots & 0 \\ 0 & \sqrt{h_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sqrt{h_n} \end{pmatrix} \quad \Omega = \begin{pmatrix} h_1 & 0 & \cdots & 0 \\ 0 & h_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & h_n \end{pmatrix}$$

# 1. Mínimos Cuadrados Ponderados (MCP)

Si dividimos el modelo por  $\sqrt{h_i}$  obtenemos un modelo transformado de la forma:

$$\tilde{y}_i = \beta_0 + \beta_1 \tilde{X}_{1i} + \beta_2 \tilde{X}_{2i} + \cdots + \beta_k \tilde{X}_{ki} + \tilde{\varepsilon}_i$$

Donde:

$$\tilde{y}_i = \frac{y_i}{\sqrt{h_i}} \quad \tilde{X}_{ji} = \frac{X_{ji}}{\sqrt{h_i}} \quad \tilde{\varepsilon}_i = \frac{\varepsilon_i}{\sqrt{h_i}}$$

El estimador MCG se obtiene regresionando:

$$Cy = \begin{pmatrix} \frac{y_1}{\sqrt{h_1}} \\ \frac{y_2}{\sqrt{h_2}} \\ \vdots \\ \frac{y_n}{\sqrt{h_n}} \end{pmatrix} \quad Cx = \begin{pmatrix} \frac{x_1}{\sqrt{h_1}} \\ \frac{x_2}{\sqrt{h_2}} \\ \vdots \\ \frac{x_n}{\sqrt{h_n}} \end{pmatrix}$$



# 1. Mínimos Cuadrados Ponderados (MCP)

Aplicando MCO al modelo transformado, se obtiene el estimador WLS (mínimos cuadrados ponderados):

$$\hat{\beta}_{WLS} = \left[ \sum_{i=1}^n w_i x_i x_i' \right]^{-1} \left[ \sum_{i=1}^n w_i x_i y_i \right]$$

Donde  $w_i = 1/h_i$ .

Los errores de este modelo son homocedásticos dado que:

$$E(\tilde{\varepsilon}_i | X) = E\left(\frac{\varepsilon_i}{\sqrt{h_i}} \middle| X\right) = \frac{E(\varepsilon_i | X)}{\sqrt{h_i}} = 0$$

$$Var(\tilde{\varepsilon}_i | X) = E\left(\frac{E(\varepsilon_i^2 | X)}{h_i} \middle| X\right) = \frac{\sigma^2 h_i}{h_i} = \sigma^2$$

# 8. Estimación bajo Heterocedasticidad

---

## 8.2 Matriz $\Omega$ desconocida

# Usando varianzas corregidas de White

El problema con el enfoque anterior es que depende de la forma inicial de la estructura de la varianza del error

- Asumir que  $\beta$  de MCO es insesgado y consistente.
- Si  $n$  es muy grande, el estimador de la matriz de  $var - cov$  de MCO consistentes con heterocedasticidad de White es:

$$Var(\hat{\beta}_{MCO}) = (X'X)^{-1}X'\hat{\Omega}X(X'X)^{-1}$$

- Estimar la matriz  $\Omega$  mediante los cuadrados de los residuos, como si fueran estimadores de las varianzas:

$$\hat{\Omega} = \begin{bmatrix} \hat{\varepsilon}_1^2 & 0 & \dots & 0 \\ 0 & \hat{\varepsilon}_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \hat{\varepsilon}_n^2 \end{bmatrix}$$

Capítulo 11 - Gujarati, D., & Porter, D. (2010). *Econometría* (Quinta edición ed.). & *P. Carril Villareal, Trad.*) México: *Mc Graw Hill educación*.

Capítulo 12 - Greene, W. H. (2000). *Análisis econométrico*. Tercera edición. Madrid.



**PUCP**