






**PUCP**



MAESTRÍA EN ECONOMÍA  
ECONOMETRÍA INTERMEDIA  
ECO743 – MÓDULO 2

## Sesión 2

# Heterocedasticidad

Docente: Juan Palomino



# Índice

1

Naturaleza del Problema

2

Causas y Consecuencias de la Heterocedasticidad

3

Detección de Heterocedasticidad

4

Estimación bajo Heterocedasticidad

# 1. Naturaleza del Problema

---

# Naturaleza de la Heterocedasticidad

## ❖ Hipótesis de homocedasticidad

$$\text{var}(\varepsilon_i) = \sigma^2, \forall i = 1, \dots, n$$

## ❖ Hipótesis de heterocedasticidad

$$\text{var}(\varepsilon_i) = \sigma_i^2, \forall i = 1, \dots, n$$

Caso especial de perturbaciones esféricas que se presenta cuando la varianza de los términos de perturbación no es la misma para cada individuo o unidad de análisis:

$$\text{Var}(\varepsilon|X) = \begin{pmatrix} \sigma_0^2 & 0 & \dots & 0 \\ 0 & \sigma_0^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_0^2 \end{pmatrix}$$

Los términos de perturbación siguen siendo independientes.

# Naturaleza de la Heterocedasticidad





Figura 1. Heterocedasticidad

## 2. Causas y Consecuencias de la Heterocedasticidad

---


# Causas de la Heterocedasticidad

1. Con base en los modelos de aprendizaje de los errores, a medida que las personas aprenden, disminuyen sus errores de comportamiento con el tiempo.



**Ejemplo.** Prueba de mecanografía

2. La presencia de datos atípicos provoca una mayor variabilidad del error.



**Ejemplo.** Relación entre precios de acciones y precios al consumidor



# Causas de la Heterocedasticidad

3. A medida que mejoran las técnicas de recolección de datos, es probable que  $\sigma_i^2$  se reduzca. **Ejemplo:** bancos con equipos complejos de procesamiento de información cometan menos errores en los informes mensuales.
4. Otra fuente de la heterocedasticidad es la asimetría en la distribución de uno o más regresores incluidos en el modelo. **Ejemplo:** variables económicas como riqueza, ingreso y escolaridad. La riqueza le corresponde a uno o cuantos individuos pertenecientes a los estratos superiores.
5. Surge debido a i) la incorrecta transformación de los datos (transformaciones de razón o de primeras diferencias) y ii) una forma funcional incorrecta (modelos lineales frente a modelos log-lineales)
6. Omisión de variables importantes en el modelo.

**Nota:** La heterocedasticidad es un problema típico de modelos que utilizan datos de corte transversal.

# Consecuencias de la Heterocedasticidad

- Estimación sesgada de la varianza,  $\sigma^2$
- Los estimadores MCO son insesgados, pero menos eficientes que los MCG (es decir, no tienen varianza mínima).
- Los intervalos de confianza y los estadísticos utilizados para resolver contrastes de hipótesis ya no son fiables. Por tanto, existe la posibilidad de extraer conclusiones erróneas.

# 3. Detección de Heterocedasticidad

---

# Detección de heterocedasticidad

- No es fácil detectar la heterocedasticidad en una situación concreta, ya que  $\sigma_i^2$  solo se puede conocer si tenemos toda la población de  $Y$  correspondiente al valor  $X_i$ .
- En algunas ocasiones la propia naturaleza del problema sugiere si es probable que exista heterocedasticidad.
- Disponemos de varias herramientas de diagnóstico que nos pueden ayudar a detectar la heterocedasticidad.
- Se clasifican en:
  - Procedimientos informales o subjetivos
  - Procedimientos formales u objetivos

# 3. Detección de Heterocedasticidad

---

## 3.1 Procedimientos Informales

Son subjetivos y se basan en la representación gráfica de los residuos:

- Se calculan los residuos estimados del modelo por MCO.
- Se representan los  $\hat{\varepsilon}_i^2$  o los  $\hat{\varepsilon}_i$  frente a los  $\hat{Y}_i$ , o bien frente a la variable que se cree que provoca la heterocedasticidad.
- Si los puntos se disponen en el gráfico de forma aleatoria, no hay evidencia de que se incumpla la hipótesis de homocedasticidad.
- Si el gráfico muestra un patrón de comportamiento (lineal, cuadrático, exponencial, etc.) es probable que haya heterocedasticidad.

# Procedimientos Informales

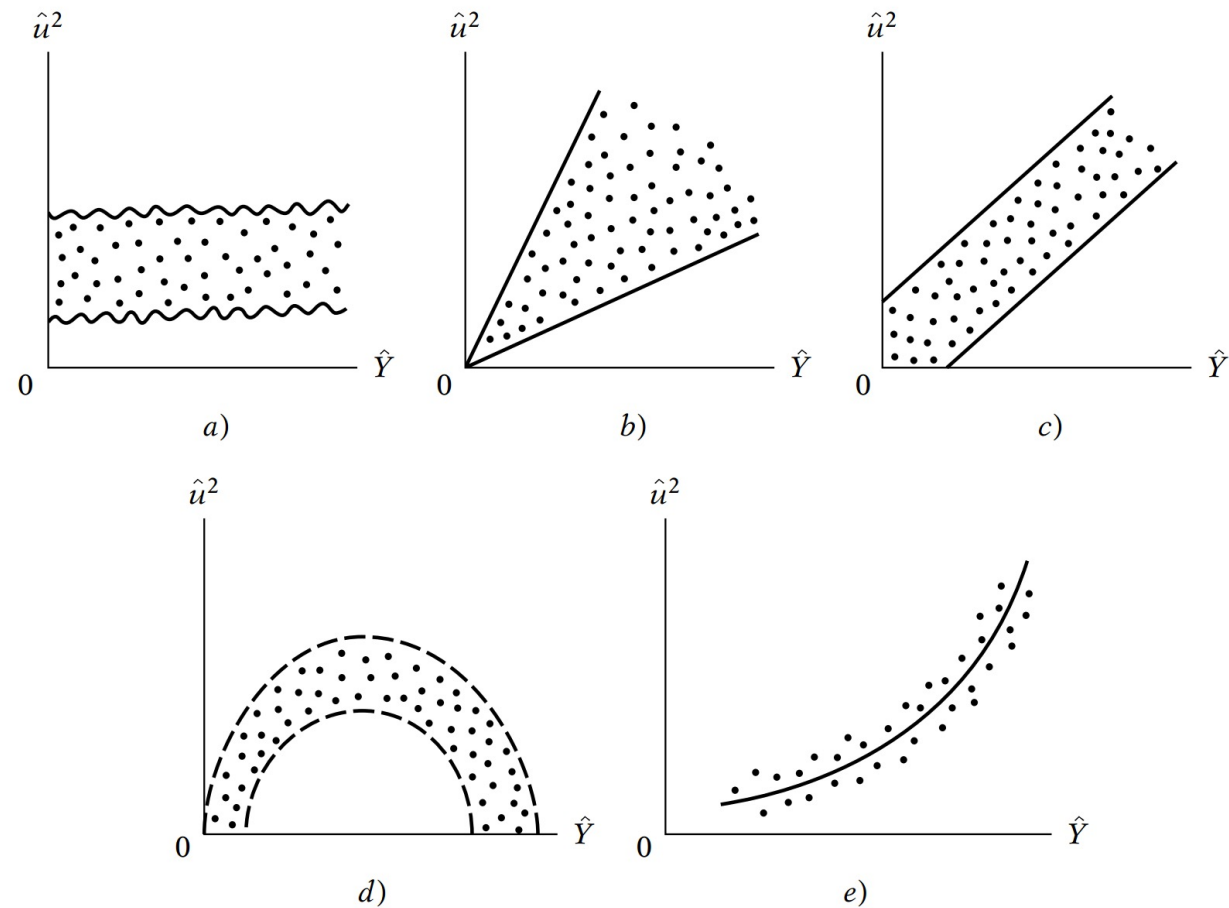


Figura 2. Procedimiento Informal

# 3. Detección de Heterocedasticidad

---

## 3.2 Procedimientos Formales



# Procedimientos Formales

Son objetivos ya que se trata de contrastes de hipótesis.

- Existe diversos test de heterocedasticidad, cada uno de los cuáles parte de un determinado supuesto acerca del posible patrón de heterocedasticidad:
  - Test de Goldfeld-Quant
  - Test de Breusch-Pagan (1979)
  - Test de Glesjer
  - Test de White (1980)
- Cada uno de estos test plantea como hipótesis nula la ausencia de heterocedasticidad pero se diferencian entre sí en la forma de plantear la hipótesis alternativa.

# Test de Goldfeld-Quant

- Este test supone que la varianza de las perturbaciones (heterocedasticidad) está relacionada, normalmente, con una de las variables explicativas del modelo.
- Bajo el supuesto de que dicha dependencia sea, por ejemplo, positiva (los menores/mayores valores de la varianza se producen cuando los valores de la variable son menores/mayores).

# Test de Goldfeld-Quant

## ❖ Pasos:

1. Ordenar de menor a mayor los valores respecto a  $X_i$ , donde se supone que ésta es la variable explicativa causante de la heterocedasticidad.
2. Se omiten las  $c$  observaciones centrales.
3. Realizar dos estimaciones por MCO utilizando las  $\frac{N-c}{2}$  primeras observaciones y las  $\frac{N-c}{2}$  últimas observaciones.
4. Calcular la suma de los cuadrados de los residuos asociados a las dos estimaciones ( $SCR_1, SCR_2$ )
5. Bajo el supuesto de homocedasticidad se verifica que:

$$\frac{SCR_2}{SCR_1} \sim F_{\frac{N-c}{2}-k}$$

Con lo cual, fijado un nivel de significancia  $\alpha$ , rechazaremos la homocedasticidad si:

$$\frac{SCR_2}{SCR_1} > F_{\frac{N-c}{2}-k; 1-\alpha}$$

## ❖ Inconvenientes:

- ¿Cómo elegir  $c$ ?  $\rightarrow c \approx \frac{N}{3}$
- ¿Y si desconocemos cuál es la variable  $X_i$  causante de la heterocedasticidad o se sospecha de varias variables a la vez?

# Test de Breusch Pagan/Godfrey

- **Supuesto:** La heterocedasticidad está provocada por una o más variables, no necesariamente presentes en el modelo lineal inicial.
- Se supone que la varianza del término de error depende de un vector de  $p$  variables  $Z$ , del siguiente modo:

$$\sigma_i^2 = f(\alpha_0 + \alpha_1 Z_{1i} + \cdots + \alpha_p Z_{pi})$$

- Donde  $f$  es una forma funcional cualquiera,  $\alpha_j$ ,  $j = 0, \dots, p$ , parámetros y  $Z_1, \dots, Z_p$  las variables presumiblemente causantes de la heterocedasticidad.
- En consecuencia, contrastar la heterocedasticidad equivale a probar la hipótesis:

$$H_0: \alpha_1 = \alpha_2 = \cdots = \alpha_p = 0$$

$$H_0: \text{Algunos de ellos es no nulo}$$

# Test Breusch Pagan/Godfrey

## ❖ Pasos:

1. Estimar la ecuación principal  $y = X\beta + \varepsilon$  por MCO y calcular los residuos y los residuos al cuadrado.
2. Calcular el estimador de  $\sigma^2$ :  $\hat{\sigma}^2 = \frac{\hat{\varepsilon}'\hat{\varepsilon}}{n}$
3. Generar una nueva variable  $g_i = \frac{\hat{\varepsilon}_i^2}{\hat{\sigma}^2}$ ,  $i = 1, \dots, n$
4. Regresionar  $g_i$  contra  $Z_1, Z_2, \dots, Z_p$ :

$$g_i = \alpha_0 + \alpha_1 Z_{1i} + \dots + \alpha_p Z_{pi} + v_i$$

5. Estimar  $\alpha_0, \dots, \alpha_p$  por MCO y calcular la SCE de la regresión auxiliar.
6. Bajo la hipótesis nula de homocedasticidad y normalidad del término de error; se sabe que:

$$\frac{1}{2} SCE \sim \chi^2_{(p-1)}$$

7. Por tanto, se rechaza la hipótesis nula de homocedasticidad cuando:

$$Q_{exp} > \chi^2_{(p-1); 1-\alpha}$$

- **Supuesto:** La heterocedasticidad está provocada por una o más variables del modelo:

$$\sigma_i^2 = f(X_2, X_3, \dots, X_k)$$

Donde  $f(\cdot)$  es una función polinómica.

# Test de White

## ❖ Pasos:

1. Estimar por MCO el modelo  $y = X\beta + \varepsilon$  y obtener los residuos  $\hat{\varepsilon}_i$  y  $\hat{\varepsilon}_i^2$ .
2. Hacer la regresión de los residuos al cuadrado con respecto a todas las variables explicativas, sus cuadrados y todos sus productos cruzados. Por ejemplo, para un modelo con dos variables explicativas:

$$\hat{\varepsilon}_i^2 = \alpha_0 + \alpha_1 X_{1i} + \alpha_2 X_{2i} + \alpha_3 X_{1i}^2 + \alpha_4 X_{2i}^2 + \alpha_5 X_{1i}X_{2i} + v_i$$

3. La hipótesis nula de homocedasticidad es:  $H_0: \alpha_i = 0$
4. Bajo esta hipótesis, el estadístico:

$$n \times R_{aux}^2 \sim \chi_p^2$$

Donde  $p$  es el número de variables explicativas en dicha regresión.

5. Así, se rechaza la hipótesis de homocedasticidad si:

$$n \times R_{aux}^2 > \chi_{p,1-\alpha}^2$$



# 4. Estimación bajo Heterocedasticidad

---

## 4.1 Matriz $\Omega$ conocida

# 1. Mínimos Cuadrados Ponderados (MCP)

- En presencia de heterocedasticidad, MCO ya no es el mejor estimador lineal insesgado.
- Si se conoce la forma de la heterocedasticidad puede usarse la estimación por Mínimos Cuadrados Ponderados (MCP) para obtener estimadores más eficientes que los de MCO.
- Los estimadores MCP nos conducen a nuevos estadísticos  $t$  y  $F$  que tienen distribuciones  $t$  y  $F$ , respectivamente.
- La idea básica del procedimiento de Mínimos Cuadrados Ponderados se basa en transformar el modelo verdadero para que el término de error sea homocedástico.

# 1. Mínimos Cuadrados Ponderados (MCP)

Siendo el modelo a estimar:

$$y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + \varepsilon_i$$

No sabemos a ciencia cierta de qué depende la varianza del error  $\varepsilon_i$ , y, por lo tanto, no sabemos cómo construir la matriz  $\Omega(X)$ .

Empezamos haciendo una conjetura acerca de esta estructura de heterocedasticidad, asumiendo que:

$$Var(\varepsilon_i | x_1, \dots, x_n) = \sigma_i^2 = \sigma_0^2 \exp(x_i' \alpha)$$

Donde  $\exp(\cdot)$  asegura que  $Var(\varepsilon_i | x_1, \dots, x_n) > 0$ . Asumimos que  $\Omega$  es diagonal. Sea  $h_i(X)$  los elementos diagonal de  $\Omega(X)$ . Por lo tanto,

$$Var(\varepsilon_i | X) = \sigma_i^2 = \sigma_0^2 h_i(X)$$

Donde  $h_i(X)$  son conocidos y positivos. Asimismo,  $h_i(X)$  determina la heterocedasticidad.

# 1. Mínimos Cuadrados Ponderados (MCP)

- ¿Qué modelo estimamos? El modelo transformado es:

$$Cy = CX\beta_0 + C\varepsilon$$

Recordar que el estimador MCG es:

$$\hat{\beta}_{MCG} = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}y$$

Donde:

$$\Omega^{-1} = \begin{pmatrix} 1/h_i & 0 & \cdots & 0 \\ 0 & 1/h_i & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1/h_i \end{pmatrix} = C'C$$

- Entonces, en este caso particular,  $\Omega^{-1}$  es matriz diagonal cuyo elemento es  $1/h_i$ . Es decir:

$$C = \begin{pmatrix} \sqrt{h_1} & 0 & \cdots & 0 \\ 0 & \sqrt{h_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sqrt{h_n} \end{pmatrix} \quad \Omega = \begin{pmatrix} h_1 & 0 & \cdots & 0 \\ 0 & h_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & h_n \end{pmatrix}$$

# 1. Mínimos Cuadrados Ponderados (MCP)

Si dividimos el modelo por  $\sqrt{h_i}$  obtenemos un modelo transformado de la forma:

$$\tilde{y}_i = \beta_0 + \beta_1 \tilde{X}_{1i} + \beta_2 \tilde{X}_{2i} + \cdots + \beta_k \tilde{X}_{ki} + \tilde{\varepsilon}_i$$

Donde:

$$\tilde{y}_i = \frac{y_i}{\sqrt{h_i}} \quad \tilde{X}_{ji} = \frac{X_{ji}}{\sqrt{h_i}} \quad \tilde{\varepsilon}_i = \frac{\varepsilon_i}{\sqrt{h_i}}$$

El estimador MCG se obtiene regresionando:

$$Cy = \begin{pmatrix} \frac{y_1}{\sqrt{h_1}} \\ \frac{y_2}{\sqrt{h_2}} \\ \vdots \\ \frac{y_n}{\sqrt{h_n}} \end{pmatrix} \quad Cx = \begin{pmatrix} \frac{x_1}{\sqrt{h_1}} \\ \frac{x_2}{\sqrt{h_2}} \\ \vdots \\ \frac{x_n}{\sqrt{h_n}} \end{pmatrix}$$

# 1. Mínimos Cuadrados Ponderados (MCP)

Aplicando MCO al modelo transformado, se obtiene el estimador WLS (mínimos cuadrados ponderados):

$$\hat{\beta}_{WLS} = \left[ \sum_{i=1}^n w_i x_i x_i' \right]^{-1} \left[ \sum_{i=1}^n w_i x_i y_i \right]$$

Donde  $w_i = 1/h_i$ .

Los errores de este modelo son homocedásticos dado que:

$$E(\tilde{\varepsilon}_i | X) = E\left(\frac{\varepsilon_i}{\sqrt{h_i}} \middle| X\right) = \frac{E(\varepsilon_i | X)}{\sqrt{h_i}} = 0$$

$$Var(\tilde{\varepsilon}_i | X) = E\left(\frac{E(\varepsilon_i^2 | X)}{h_i} \middle| X\right) = \frac{\sigma^2 h_i}{h_i} = \sigma^2$$

# 4. Estimación bajo Heterocedasticidad

---

## 4.2 Matriz $\Omega$ desconocida

# Usando varianzas corregidas de White

El problema con el enfoque anterior es que depende de la forma inicial de la estructura de la varianza del error

- Asumir que  $\beta$  de MCO es insesgado y consistente.
- Si  $n$  es muy grande, el estimador de la matriz de  $var - cov$  de MCO consistentes con heterocedasticidad de White es:

$$Var(\hat{\beta}_{MCO}) = (X'X)^{-1}X'\hat{\Omega}X(X'X)^{-1}$$

- Estimar la matriz  $\Omega$  mediante los cuadrados de los residuos, como si fueran estimadores de las varianzas:

$$\hat{\Omega} = \begin{bmatrix} \hat{\varepsilon}_1^2 & 0 & \dots & 0 \\ 0 & \hat{\varepsilon}_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \hat{\varepsilon}_n^2 \end{bmatrix}$$





**PUCP**